

ObiOne: um observatório de projetos viabilizado por IA Generativa

Bruno Rocha, Cynthia Oliveira, Moisés Júnior, Raniel Silva

Escola Politécnica de Pernambuco — Universidade de Pernambuco (UPE)

Recife — PE — Brasil

Orientador: Prof. Ivaldir Honório de Farias Júnior

{bruno.rocha, cynthia.oliveira, moises.junior, raniel.silva}@upe.br

Resumo. Consultorias acumulam conhecimento valioso a cada projeto, mas raramente dispõem de um sistema leve o bastante para preservá-lo e reaproveitá-lo entre clientes. Este artigo apresenta o ObiOne, um observatório de projetos construído sobre o Modelo de Observatório de Projetos (MPO) e potencializado por IA Generativa. O trabalho segue a Design Science Research: além de construir o artefato, avalia seu funcionamento real (ciclo exercitado de ponta a ponta com IA da OpenAI) e a percepção de valor em duas rodadas de piloto, com oito consultores no total. No acumulado os resultados foram positivos (média 4,3 de 5); a segunda rodada, após a inclusão de um onboarding e com um público mais diverso, foi mais crítica (4,1 ante 4,48) e manteve a clareza inicial (3,8) como o principal ponto de atenção. A principal contribuição é a demonstração empírica de que o MPO é implementável com IA generativa em uma consultoria real.

1. Introdução

Consultorias entregam, ano após ano, dezenas de projetos para clientes distintos, e cada projeto produz um conhecimento valioso: o que funcionou, os riscos que se materializaram e as decisões que mudaram o rumo do trabalho. Esse conhecimento, porém, tende a permanecer tácito, preso a quem viveu o projeto, e raramente é capturado de forma reaproveitável. Revisões sistemáticas sobre gestão do conhecimento mostram que a captura, a análise e a aplicação de lições aprendidas dependem mais de fatores culturais e organizacionais do que das ferramentas adotadas (Henz, 2024; Kamudyariwa et al., 2025). O obstáculo prático é o custo: manter um repositório vivo de conhecimento exige um esforço contínuo que poucas consultorias de pequeno e médio porte conseguem sustentar. A consequência é conhecida: erros se repetem entre projetos, há retrabalho e parte do aprendizado se perde na transição de um caso para o outro.

Observatórios de projetos são uma resposta a esse problema. São sistemas de informação que apoiam a coleta, a organização, o armazenamento, a análise e a publicação de observações, sistematizando a transparência sobre o andamento e as decisões dos projetos (Vieira et al., 2021). O Modelo de Observatório de Projetos

(MPO) consolida essa abordagem em um conjunto de conceitos hierárquicos que orienta a concepção desses sistemas (Vieira, 2022; de Farias Junior et al., 2025). O que distingue um observatório de uma ferramenta comum de gestão é justamente tratar a observação, e não apenas a execução, como objeto de primeira classe: ferramentas usuais, como quadros de tarefas e painéis, registram o que foi feito, mas não capturam o porquê das decisões nem transformam observações em conhecimento compartilhado.

No contexto de uma consultoria, o portfólio se organiza por áreas de atuação e os clientes se renovam a cada engajamento, o que torna o reaproveitamento de aprendizados entre casos especialmente valioso. Além disso, o cliente não é apenas destinatário do resultado: ele participa das decisões e detém informação que enriquece a observação. Abrir o observatório, de forma controlada, à participação do cliente cria uma dimensão comunitária que a literatura de observatórios, centrada na organização executora, ainda não explora.

Diante desse cenário, sobressaem-se duas lacunas. A primeira é técnica e empírica: embora o MPO tenha sido validado conceitualmente e em estudos de caso (de Farias Junior et al., 2025), nenhuma implementação conhecida o operacionaliza com IA generativa. A segunda é comunitária: os observatórios descritos na literatura tratam da organização executora, sem explorar a participação do cliente como ator do ciclo de conhecimento. A IA generativa surge, nesse ponto, como uma janela de oportunidade, pois reduz o custo de extrair e sintetizar informação textual, tarefa antes cara e manual.

Este artigo investiga como a IA generativa pode viabilizar um observatório de projetos, de modo a reduzir a fricção de manutenção e promover o engajamento entre a organização executora e seus clientes. Desse objetivo geral derivam três objetivos específicos: demonstrar a viabilidade técnica de operacionalizar o MPO com IA generativa; construir e exercitar a dimensão comunitária, em que consultoria e clientes debatem observações e consolidam aprendizados; e avaliar a percepção de valor da solução por usuários reais.

Para responder a essa pergunta, o trabalho apresenta o ObiOne, um observatório de projetos construído sobre o MPO e potencializado por IA generativa, e segue a Design Science Research, que trata a construção do artefato como forma legítima de investigação. O restante do artigo está organizado como segue: a Seção 2 apresenta a fundamentação teórica; a Seção 3, o método; a Seção 4, a implementação do artefato; a Seção 5, os resultados da avaliação; a Seção 6, a discussão e as lições aprendidas; e a Seção 7, a conclusão.

2. Fundamentação Teórica

2.1. Observatórios de projetos e o MPO

A observação é um elemento antigo da gestão, e a transparência é o construto que, na literatura recente, traduz a observação no contexto de projetos: tornar visíveis o

andamento, as decisões e os riscos fortalece o alinhamento entre a organização e seus interessados (Vieira et al., 2021). Observatórios de projetos são os sistemas de informação que sistematizam essa transparência, apoiando a coleta, a organização, o armazenamento, a análise e a publicação de observações.

O Modelo de Observatório de Projetos (MPO) é um modelo conceitual para esses sistemas, organizado a partir de 61 conceitos estruturados em três níveis hierárquicos, do geral ao específico (de Farias Junior et al., 2025). Sua versão de tese sistematiza os atributos de observação no Quadro 37, que reúne 44 atributos distribuídos em oito dimensões, abrangendo desde dados estruturais do projeto até registros narrativos como escopo, riscos e lições aprendidas (Vieira, 2022). O modelo parte de uma perspectiva sociotécnica e relaciona transparência e governança a sistemas de apoio à gestão de projetos; foi avaliado conceitualmente e em estudos de caso (de Farias Junior et al., 2025), mas ainda não havia sido operacionalizado com apoio de IA generativa.

2.2. Gestão do conhecimento em projetos

A gestão do conhecimento trata da captura e do reaproveitamento do que se aprende ao longo do trabalho, e as lições aprendidas são uma de suas práticas centrais em projetos. Revisões sistemáticas recentes indicam que a implementação efetiva depende sobretudo de fatores humanos e organizacionais, como cultura, apoio gerencial e melhoria contínua, e que, sem esses fatores, as práticas de lições aprendidas tendem a falhar independentemente das ferramentas empregadas (Henz, 2024).

Em projetos complexos, a aprendizagem organizacional se sustenta quando a captura, a análise e a aplicação de lições são conduzidas de forma sistemática, e não pontual (Kamudyariwa et al., 2025). Esse é o ponto em que as ferramentas usuais de gestão mostram seu limite: elas registram o que foi feito, mas não o porquê, e não oferecem um lugar nem um ritual para que o conhecimento seja debatido e consolidado. O observatório atua exatamente sobre essa lacuna.

2.3. IA Generativa como assistente

Modelos de linguagem de grande porte têm sido estudados como apoio a tarefas de análise textual, entre elas a codificação e a síntese qualitativa. Estudos recentes mostram que a IA acelera a identificação de temas descritivos e reduz o esforço operacional, mas perde nuances que dependem de conhecimento contextual humano (CHI, 2026; medRxiv, 2024).

Daí emerge um consenso de parceria guiada: a IA assume tarefas estruturadas enquanto o humano permanece como líder intelectual da interpretação, princípio conhecido como human-in-the-loop. Para um observatório, isso sugere um papel assistivo para a IA, capaz de reduzir a fricção de registrar e sintetizar conhecimento sem

substituir o julgamento de quem conduz o projeto. É essa a posição adotada pelo ObiOne.

3. Método

3.1. Design Science Research

A construção do ObiOne segue a Design Science Research, que estabelece o artefato como forma legítima de pesquisa (Hevner et al., 2004) e organiza o trabalho em atividades de identificação do problema, definição de objetivos, design e desenvolvimento, demonstração, avaliação e comunicação (Peppers et al., 2007). Por se tratar de uma pergunta de viabilidade, responder exige construir o sistema, colocá-lo em uso e observar o resultado, e não apenas coletar opiniões sobre uma descrição.

3.2. Desenho da avaliação

A avaliação combinou a demonstração de uso real do artefato com a medição da percepção de valor. A percepção foi medida por um instrumento de doze afirmações em escala Likert de 1 a 5 e três perguntas abertas, aplicado em duas rodadas de piloto com quatro consultores cada, após um walkthrough do sistema. A segunda rodada ocorreu depois da inclusão de um onboarding de primeiro acesso e reuniu um público mais diverso. Como as duas rodadas usaram participantes distintos, a comparação é exploratória e carrega um confundidor: a variação entre rodadas mistura o efeito das mudanças no produto com a diferença de composição das coortes. A avaliação foi conduzida na perspectiva do consultor, perfil central do observatório; a aplicação, porém, oferece telas para os três perfis, consultor, administrador e cliente, conforme o Apêndice C. Os resultados são reportados como casos, sem inferência estatística.

3.3. Participantes

As duas rodadas somaram oito participantes de uma mesma consultoria, quatro em cada rodada. Quanto ao papel, sete eram consultores e um era gestor. As ferramentas de acompanhamento de projetos usadas no dia a dia eram sobretudo o Trello, por quatro participantes, e planilhas, por três. A familiaridade com gestão de projetos era, na maioria, de nível médio. A Tabela 1 resume o perfil.

Tabela 1. Perfil dos participantes (N=8, duas rodadas de quatro).

Dimensão	Distribuição
Rodadas	4 na primeira; 4 na segunda
Papel	7 consultores; 1 gestor
Ferramenta de projetos usada hoje	4 Trello; 3 planilhas; 1 outra
Familiaridade com gestão de projetos	2 alto; 5 médio; 1 baixo

4. Implementação

4.1. Requisitos e rastreabilidade ao MPO

O ObiOne foi desenvolvido para uma consultoria de marketing, que atua como organização executora e curadora, e seus clientes, que acessam cada um o próprio projeto. A elicitação e a especificação seguiram práticas usuais de engenharia de requisitos (Sommerville, 2016), e cada requisito funcional foi ancorado a uma característica ou processo do MPO, de modo que o artefato implementasse o modelo, e não apenas se inspirasse nele. A Tabela 2 apresenta uma amostra; a rastreabilidade completa está no Apêndice A.

Tabela 2. Amostra da rastreabilidade requisito → MPO → implementação.

Requisito (ObiOne)	Âncora no MPO	Implementação
Catálogo de atributos de observação	Quadro 37: 44 atributos em 8 dimensões (Vieira, 2022)	mpo/MpoCatalog
Cobertura de observação por projeto	Característica Abrangência (Vieira, 2022)	GET /projects/{id}/coverage
Governança de acesso por papel	Característica Segurança (Vieira, 2022)	filtro por papel (consultor/cliente)
Registro e acompanhamento	Processos Acompanhar e Avaliar (Vieira, 2022)	ciclo observação → conversa → aprendizado
Consolidação de aprendizados	Transparência e disseminação (de Farias Junior et al., 2025)	comunidade por domínio

A cobertura resultante abrange os 44 atributos de observação previstos pelo MPO, distribuídos em oito dimensões. Trata-se de cobertura arquitetural: o sistema provê os campos e os fluxos correspondentes. A avaliação empírica da qualidade da extração é uma frente prevista no protocolo, ainda não executada (Seção 5.4).

4.2. Arquitetura

O ObiOne é uma aplicação web dividida em backend e frontend. O backend usa Java 21 e Spring Boot, com os módulos web, data-jpa, security e validation, e segue uma organização por contexto de domínio em camadas: controladores REST finos, serviços com a lógica de negócio, repositórios Spring Data, entidades JPA e objetos de transferência de dados com mapeadores dedicados. A persistência de desenvolvimento usa um banco H2 em arquivo, com PostgreSQL previsto para produção. O frontend usa React com TanStack Start e roteamento baseado em arquivos, construído com Vite; o estado de servidor é gerido por react-query e os formulários por react-hook-form com validação por esquema. A API responde sob o caminho base barra-api, e a aplicação adota um padrão de origem única: o servidor de desenvolvimento serve a interface e encaminha as chamadas de API ao backend, o que simplifica o acesso remoto para as sessões de validação.

4.3. Camada de IA

A camada de IA é o principal diferencial do ObiOne e atua de forma assistiva sobre o ciclo de observação, conversa e aprendizado. Está organizada em cinco papéis; em

todos, a saída é uma sugestão, nunca uma ação publicada automaticamente. A Tabela 3 resume os papéis, com suas entradas e saídas.

Tabela 3. Papéis da camada de IA, com entradas e saídas.

Papel	Função	Entrada	Saída
Categorizadora	Sugere o domínio do projeto	resumo, objetivo, domínios disponíveis	domínio sugerido e confiança
Observadora	Sugere observações ancoradas no MPO	resumo, objetivo, lente MPO, atributos prioritários, observações já registradas	observações mapeadas a atributos, com impacto e trecho literal
Sintetizadora	Rascunha um aprendizado a partir da conversa	título, pergunta, contribuições	rascunho com resumo, evidência e recomendação
Conectora	Sintetiza padrões entre projetos do domínio (implementada; não avaliada)	resumos dos projetos do domínio	padrões e lições anonimizados
Configuradora	Sugere o setup inicial no cadastro	nome, descrição, objetivo	domínio, atributos e fenômenos esperados

O processamento de um projeto segue um fluxo comum. A partir do texto do projeto, o serviço assistente reúne o contexto e o analisa à luz dos atributos de observação do MPO; aciona a IA, que devolve uma sugestão estruturada; registra essa sugestão de forma auditável, com sua proveniência; e a devolve ao consultor para revisão. A Figura 1 ilustra esse fluxo.

Descrição do projeto → Análise pela IA à luz do MPO → Sugestão estruturada e auditável → Revisão do consultor → Observação ou aprendizado publicado
--

Figura 1. Pipeline da camada de IA.

Quatro técnicas sustentam a confiabilidade das sugestões. A primeira é a saída estruturada: o modelo é obrigado a responder no formato de um objeto de dados, que o sistema mapeia diretamente, sem interpretação livre do texto. A segunda é o grounding pela lente do MPO, reforçado por instruções que orientam o modelo a não inventar atributos fora da lista fornecida e a citar o trecho literal do resumo que motivou cada observação. A terceira é uma validação determinística em código: na configuração inicial de um projeto, identificadores de atributo ou de domínio inexistentes no catálogo são descartados antes de a resposta ser devolvida. A quarta é a consciência do estado do observatório: ao sugerir observações, o modelo recebe a lista do que o projeto já registra e é instruído a não repetir aspectos em observação, e um filtro determinístico descarta, em código, qualquer sugestão cujo atributo já esteja coberto, mesmo que o modelo desobedeça. O provedor é configurável: um modo determinístico, sem chave e voltado a testes, e o provedor da OpenAI, com o modelo gpt-5.4-mini e temperatura baixa, para uso real.

A IA nunca escreve diretamente nas observações ou nos aprendizados. Ela apenas sugere e registra cada sugestão em um log de auditoria, com o provedor, o modelo, o instante e a indicação de aceite, o que dá reprodutibilidade ao uso da IA. A persistência só ocorre quando o consultor aceita a sugestão, e a observação é então gravada com a origem marcada como assistida pela IA. A taxa de aceite por tipo de sugestão é observável no sistema, permitindo acompanhar o quanto as sugestões são de fato aproveitadas. No caso da Conectora, a própria síntese fica persistida nesse log: o sistema recupera a última versão por domínio, com a data de geração, e oferece a regeneração sob demanda, tratando o resultado como um artefato de conhecimento versionado, e não como uma saída efêmera.

4.4. Prototipação

Antes do desenvolvimento final, as telas foram prototipadas com apoio de ferramentas de geração assistida por IA no ecossistema React, incluindo o Lovable, que produziu o scaffold inicial da interface e da sua configuração de build. A prototipação rápida corresponde à atividade de design e desenvolvimento da Design Science Research e serviu de insumo concreto para as validações com os orientadores, encurtando o ciclo entre uma ideia de tela e uma versão navegável.

4.5. Governança por papel

O acesso ao observatório é semi-aberto e governado pelo papel do usuário. As leituras exigem autenticação; as mutações são restritas aos papéis de consultor e administrador, enquanto o cliente contribui nas conversas e enxerga apenas o seu próprio projeto. O consultor conduz a curadoria e vê todo o portfólio; o administrador acumula as permissões de gestão; o cliente participa da comunidade do seu caso sem acesso às ações de equipe nem à visão consolidada do portfólio. A configuração dessas permissões é, ela própria, governada por regras assimétricas: o perfil do administrador é fixo, com todas as permissões habilitadas e imutáveis; apenas o administrador altera as permissões do consultor; e o consultor gerencia apenas as do cliente, com as regras aplicadas no backend, e não apenas na interface. A integridade da evidência segue o mesmo princípio: uma observação com conversa vinculada não pode ser excluída, preservando o registro que sustenta o debate da comunidade. Esse arranjo garante o isolamento entre clientes e materializa, na prática, o acesso semi-aberto previsto no MPO. As telas correspondentes a cada perfil estão no Apêndice C.

4.6. Jornada do usuário e construção do MVP

A jornada central percorre quatro momentos: o cadastro de um projeto assistido por um wizard com apoio de IA, o registro de observações ancoradas no MPO, a conversa da comunidade sobre essas observações e a consolidação de aprendizados reaproveitáveis. Um feed reflete a atividade recente e a cobertura de cada projeto frente ao MPO é consultável. O MVP foi construído em torno desse fluxo e entregou o cadastro com extração assistida, a organização da comunidade por domínio, o detalhe do projeto com

os atributos do MPO, a consolidação de aprendizados com apoio da Sintetizadora, o feed de novidades e, após a primeira rodada de validação, um onboarding de primeiro acesso que apresenta o objetivo do sistema e o ciclo de conhecimento.

5. Resultados

5.1. Viabilidade técnica

Em junho de 2026, o ciclo foi exercitado de ponta a ponta com a IA da OpenAI e dados de simulação. As quatro frentes assistivas operaram de forma integrada: cadastro, sugestão de observações priorizadas pelos riscos declarados, aceite pelo consultor, alimentação da cobertura, conversa com participação do cliente e atualização do feed. A governança por papel foi confirmada na interface.

5.2. Percepção de valor

A percepção de valor foi medida em duas rodadas de piloto com quatro consultores cada, aplicando o mesmo instrumento de doze afirmações Likert e três perguntas abertas. A primeira rodada ocorreu após um walkthrough curto; a segunda, após a inclusão de um onboarding de primeiro acesso e outros ajustes, com um público mais diverso (incluindo um gestor e mais usuários de planilhas). A primeira rodada obteve média 4,48 de 5, com 44 de 48 respostas nas notas 4 ou 5 e 29 máximas. A segunda foi mais crítica: média 4,1, com 36 de 48 respostas positivas e 19 máximas. No acumulado dos oito participantes, a média foi 4,3 de 5, com 80 de 96 respostas positivas. A Tabela 4 apresenta o comparativo por dimensão entre as duas rodadas.

Tabela 4. Médias por dimensão nas duas rodadas (escala 1 a 5, N=4 por rodada).

Dimensão	1ª rodada	2ª rodada	Δ
Clareza	3,8	3,8	0,0
Organização	4,8	4,0	-0,8
Usabilidade	4,5	4,5	0,0
Conteúdo	4,8	4,8	0,0
Diferenciação	4,2	3,8	-0,5
Ciclo de conhecimento	4,0	4,2	+0,2
Comunidade	4,8	4,3	-0,5
Aprendizados	5,0	4,2	-0,8
IA assistiva	4,5	4,0	-0,5
Portfólio	4,2	4,2	0,0
Governança	5,0	3,8	-1,2
Intenção de uso	4,2	4,0	-0,2

A segunda rodada leu o produto de forma mais crítica em governança (-1,2), organização e aprendizados (-0,8 cada), comunidade, diferenciação e IA assistiva (-0,5 cada). Conteúdo, usabilidade, portfólio e, notadamente, a clareza permaneceram estáveis, e o ciclo de conhecimento evoluiu (+0,2). A queda é atribuída, em parte, a um público mais diverso e crítico e, em parte, à fricção inicial que persiste: isolar o efeito do onboarding exigiria um desenho controlado com os mesmos usuários antes e depois.

Ainda assim, o valor central se manteve nas respostas abertas, em que a IA passou a aparecer como força (“aprendizado consolidado através da IA”) e o produto foi descrito como amigável e que integra tecnologia e educação. O feedback crítico, por sua vez, concentrou-se na experiência inicial: um participante relatou que “ficou um pouco confusa a explicação sobre algumas funcionalidades”, e os pedidos de melhoria convergiram para “navegação mais intuitiva, instruções mais claras e interface mais simples”.

5.3. Benefícios esperados

Os benefícios esperados com a solução incluem a redução do custo de manutenção do conhecimento entre projetos, o fortalecimento do relacionamento com os clientes por meio de maior engajamento e comunicação na comunidade, e o reaproveitamento de aprendizados já consolidados em novos projetos do mesmo domínio.

5.4. Limitações

As duas rodadas somam oito participantes de uma mesma consultoria, em ciclos distintos e com composição diferente; os resultados são reportados como casos, sem inferência estatística, e a comparação entre rodadas é exploratória. A clareza permaneceu como o principal ponto de atenção (3,8 nas duas rodadas): a inclusão de um onboarding de primeiro acesso não moveu esse indicador, o que sugere que a orientação inicial precisa ir além de um passo introdutório, na direção de uma navegação mais guiada. Como a segunda rodada usou participantes distintos, não é possível separar o efeito do onboarding da mudança de público. Por fim, a avaliação da qualidade da extração dos atributos do MPO, prevista no protocolo, ainda não foi executada.

6. Discussões e Lições Aprendidas

Os resultados confirmam o MPO como base válida e mostram que ele é implementável com IA generativa a um custo viável para uma consultoria de pequeno e médio porte. Estudos anteriores avaliaram o modelo conceitualmente e em casos (de Farias Junior et al., 2025); o ObiOne acrescenta uma implementação operacional com IA. A IA reduz a fricção de iniciar o ciclo; à objeção de que criaria dependência, o desenho responde com o human-in-the-loop, e as respostas abertas sustentam que o valor percebido está no que a comunidade produz e no aprendizado consolidado com apoio da IA. A segunda rodada, mais crítica, deixa claro que a restrição dominante para a adoção não está no ciclo em si, mas na experiência inicial: enquanto a clareza e a navegação não forem resolvidas, o valor demora a ser percebido. O fato de o onboarding não ter movido a clareza indica que o próximo passo é uma navegação guiada, com menu evidente, fluxo em etapas e exemplos práticos.

Essa leitura já produziu um terceiro ciclo de design, posterior à segunda rodada. O cadastro tornou-se IA-first, com a descrição textual como único insumo e degradação graciosa quando a IA não responde; o ciclo de observação, conversa e consolidação

passou a acontecer em uma única tela, com um clique para abrir a conversa e o diálogo de consolidação reduzido ao essencial; e as telas foram enxugadas para diminuir a carga de leitura. Essas mudanças respondem diretamente à restrição de clareza apontada pela avaliação, mas ainda não foram reavaliadas: a rodada controlada prevista nas questões em aberto é o teste natural desse redesenho.

Como decisões arquiteturais, destacam-se a IA estritamente assistiva e a governança por papel, que viabiliza o acesso semi-aberto com isolamento entre clientes. Entre vantagens e limitações das ferramentas, o desenvolvimento em código deu controle sobre o pipeline e a governança, ao custo de mais esforço do que uma abordagem low-code. A experiência de uso do MPO mostrou que traduzir 44 atributos em uma interface sem jargão é mais difícil do que implementá-los.

A lição mais marcante foi de escopo. O projeto passou por um pivô: a proposta inicial foi reescopada para refinar o propósito da solução, deslocando o foco de um extrator de atributos para um observatório de projetos com participação dos clientes. Esse refino exigiu bastante trabalho ao longo de várias validações com os orientadores, e foi ele, mais do que qualquer ganho de ferramenta, que destravou o valor percebido. A IA generativa acelerou a construção, mas mostrou um limite claro: sem uma definição nítida do que se está construindo, a velocidade da IA não leva a lugar nenhum; ela amplifica a direção que já existe, não a substitui.

Amarradas a essa jornada, as lições de equipe se somam às de escopo. No plano operacional, o escopo amplo frente ao prazo exigiu disciplina de cronograma e trabalho de preparação de dados e integração contínua, com deslizes de data corrigidos ao longo do projeto. No plano técnico, os principais desafios foram a integração da IA, a configuração de acesso remoto para validação e a manutenção do ambiente. No plano conceitual, entender o MPO em profundidade foi determinante. No plano de equipe, coordenar quatro integrantes e integrar frentes de extração, frontend, avaliação e escrita exigiu comunicação constante.

7. Conclusão

O custo de manter um observatório de projetos caiu com a IA generativa, mas o diferencial de valor é a comunidade, e isso não é substituível por tecnologia. Como síntese da experiência, o ObiOne demonstra empiricamente que o MPO é implementável com IA generativa em uma consultoria real, e que a participação de consultoria e clientes em um ciclo comum de conhecimento distingue o observatório de uma ferramenta de gestão. A principal contribuição é essa demonstração empírica.

Questões em aberto

A leitura comparativa das duas rodadas deixa cinco questões que delimitam os gaps da pesquisa e orientam sua continuidade: (1) o onboarding melhora a clareza quando medido nos mesmos usuários antes e depois, isolando o efeito da mudança de público?

(2) uma navegação guiada, com menu evidente, fluxo em etapas e exemplos práticos, eleva a clareza acima do patamar observado de 3,8? (3) qual a acurácia e a fidelidade da extração dos atributos do MPO pela IA, conforme o protocolo ainda não executado? (4) a IA melhora a qualidade dos aprendizados consolidados, e não apenas reduz a fricção de iniciar o ciclo? (5) o padrão de valor percebido se mantém em outros domínios, com amostra maior e uso prolongado, e o que explica a queda na percepção de governança na segunda rodada?

Essas questões orientam os trabalhos futuros: realizar uma nova rodada controlada, com os mesmos usuários antes e depois do redesenho IA-first e da navegação guiada; ampliar a validação com mais participantes e domínios; executar o protocolo de avaliação da extração do MPO; e avaliar a síntese cross-projeto (Conectora), já implementada com anonimização e com cada síntese persistida no log de auditoria, cuja avaliação de valor permanece em aberto.

Referências

- de Farias Junior, I. H., Vieira, J. K. M., de Moura, H. P. and Sampaio, L. T. (2025) "A Conceptual Model for Project Observatories", IEEE Access, v. 13. DOI: 10.1109/ACCESS.2025.3589743.
- Henz, P. (2024) "Knowledge management implementation: A systematic literature review", Knowledge and Process Management. DOI: 10.1002/kpm.1780.
- Hevner, A. R., March, S. T., Park, J. and Ram, S. (2004) "Design Science in Information Systems Research", MIS Quarterly, v. 28, n. 1, p. 75-106. DOI: 10.2307/25148625.
- Kamudyariwa, X. B., Osobajo, O. A., Oke, A. and Adebayo, Y. (2025) "Application of the systemic lessons learned knowledge model to learning in complex projects". DOI: 10.1177/13505076251339433.
- Peppers, K., Tuunanen, T., Rothenberger, M. A. and Chatterjee, S. (2007) "A Design Science Research Methodology for Information Systems Research", Journal of Management Information Systems, v. 24, n. 3, p. 45-77. DOI: 10.2753/MIS0742-1222240302.
- Sommerville, I. (2016) "Software Engineering", 10ª ed., Pearson Education, Boston.
- "Generative AI for Thematic Analysis in a Maternal Health Study: Coding Semi-structured Interviews using Large Language Models" (2024), medRxiv (preprint). DOI: 10.1101/2024.09.16.24313707.
- "Qualitative Coding Analysis through Open-Source Large Language Models: A User Study and Design Recommendations" (2026), In: CHI Conference on Human Factors in Computing Systems, Extended Abstracts. DOI: 10.1145/3772363.3798320.

Vieira, J. K. M. (2022) "Observatórios de Projetos: Um Modelo Conceitual", Tese de Doutorado, Centro de Informática, Universidade Federal de Pernambuco, Recife.

Vieira, J. K. M., de Farias Junior, I. H. and de Moura, H. P. (2021) "Observatories as Transparency Instruments for Projects", In: 16ª Conferência Ibérica de Sistemas e Tecnologias de Informação (CISTI).

Apêndices

Apêndice A - Requisitos e rastreabilidade ao MPO

A Tabela A.1 relaciona os principais requisitos funcionais do ObiOne às características e processos do MPO (Vieira, 2022) e à sua materialização no sistema. A especificação completa dos requisitos está no repositório.

Tabela A.1. Rastreabilidade dos requisitos funcionais ao MPO.

RF	Requisito	Âncora no MPO (Vieira, 2022)	Implementação
RF01	Autenticar usuário	Segurança (p. 192)	auth por token JWT stateless; SecurityConfig
RF02	Perfis e acesso semi-aberto	Acesso semi-aberto (p. 189); agentes (pp. 200-201)	papéis consultor/admin/cliente
RF03	Cadastrar projeto (descrição textual)	Coletar (p. 195)	wizard de cadastro
RF04	Governança de visibilidade por papel	Acesso semi-aberto (p. 189); Segurança (p. 192)	enforcement por papel
RF05	Extrair atributos do MPO via IA	Quadro 37 (p. 264); Transformar (p. 196)	camada de IA (Observadora)
RF06	Persistir extração estruturada	Armazenar (p. 196)	entidades JPA
RF07	Portfólio perfil-aware	Abrangência (p. 189); Disponibilizar (p. 196)	listagem por papel
RF08	Detalhe do projeto	Projetos (p. 186); Disponibilizar (p. 196)	detalhe com atributos MPO
RF09	Cobertura do MPO	Abrangência (p. 189); Avaliar (p. 198)	GET /projects/{id}/coverage
RF10	Comentar/conversar no projeto	Interatividade (p. 191); Interagir (p. 198)	discussões da comunidade
RF11	Feed de novidades	Acompanhar (p. 198)	feed temporal in-app
RF12	Consolidar aprendizados (IA)	Transformar; Categorizar (pp. 196-197)	camada de IA (Sintetizadora)
RF13	Categorizar por	Categorizar/	camada de IA

	temática/domínio	Classificar (pp. 196-197)	(Configuradora)
--	------------------	---------------------------	-----------------

Repositório: <https://github.com/raniel90/obione>

Especificação de requisitos: <https://github.com/raniel90/obione/blob/main/atividades/requisitos.md>

Apêndice B - Arquitetura do Observatório

A arquitetura em camadas do backend, com controladores, serviços, repositórios, entidades e mapeadores, e o pipeline da camada de IA estão descritos em detalhe nos documentos de arquitetura do repositório, listados a seguir.

Arquitetura do backend: https://github.com/raniel90/obione/blob/main/atividades/arquitetura_backend.md

Pipeline da camada de IA: https://github.com/raniel90/obione/blob/main/atividades/arquitetura_pipeline.md

Diagrama da arquitetura: https://github.com/raniel90/obione/blob/main/atividades/arquitetura_diagrama.md

Apêndice C - Telas por perfil

A Tabela C.1 resume quais perfis acessam cada tela; em seguida, as Figuras C.1 a C.6 ilustram as telas principais. O conjunto completo de telas está em Principais_Telas_ObiOne.pdf, no repositório.

Tabela C.1. Telas e perfis que as acessam.

Tela	Consultor	Administrador	Cliente
Observatório (home)	sim	sim	visão limitada
Comunidade	sim	sim	sim (seu domínio)
Detalhe do projeto	sim (todos atributos)	sim	sim (seu projeto)
Feed de novidades	sim	sim	sim
Consolidar com IA	sim	sim	não
Wizard de cadastro	sim	sim	não




Figura C.1. Observatório (home).




Figura C.2. Comunidade.




Figura C.3. Detalhe do projeto.




Figura C.4. Feed de novidades.




Figura C.5. Consolidar aprendizado com IA.




Figura C.6. Wizard de cadastro de projeto.